Inteligență Artificială - Tema 2

Utilizarea modelelor neurale pentru clasificarea imaginilor

Raport de rezultate și interpretare

Autor: Mircea Bianca-Anastasia
Grupa: 333CC

1. Introducere și descrierea datelor

Setul „Vai de pielea mea” conține imagini dermatoscopice RGB cu 7 clase de diagnostic. Setul „You’re on candid camera” conține imagini RGB de expresii faciale, tot cu 7 clase. Ambele seturi sunt dezechilibrate, motiv pentru care metricile principale urmărite au fost F1-macro, F1-micro și accuracy, nu doar acuratețea globală.

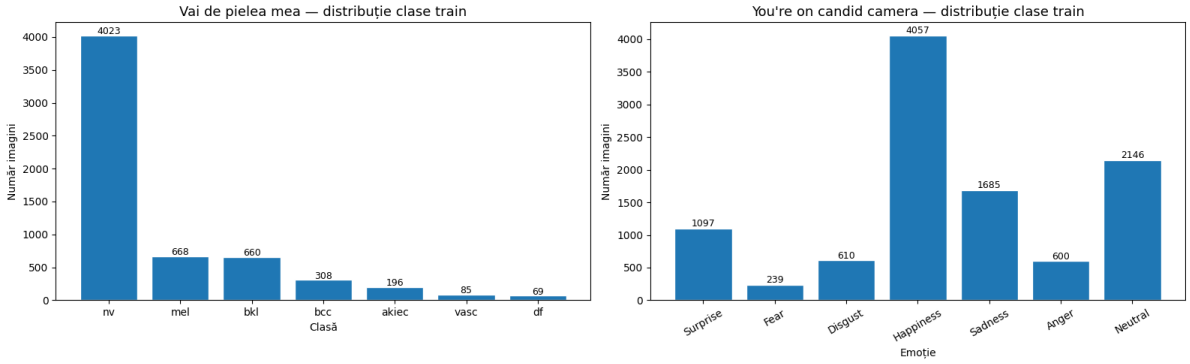


Figura 1. Distribuția claselor în seturile de antrenare.

2. Pipeline de preprocesare și augmentare

Imaginile au fost încărcate prin clase Dataset personalizate și au fost transformate în tensori PyTorch. Pentru modelele simple s-au folosit redimensionări apropiate de rezoluția originală, iar pentru fine-tuning s-au folosit dimensiuni compatibile cu modele preantrenate pe ImageNet. Normalizarea a fost realizată cu statisticile datasetului sau cu statisticile ImageNet pentru modelele preantrenate.

Augmentările au fost aplicate doar pe setul de antrenare. Pentru skin au fost folosite flip-uri, rotații și modificări moderate de culoare, deoarece leziunile nu au o orientare semantică fixă. Pentru camera s-au folosit augmentări mai prudente: flip orizontal, rotații mici, crop-uri și ColorJitter moderat; nu s-au folosit flip-uri verticale, deoarece acestea ar schimba semantica unei fețe.

3.1 Augmentări — Vai de pielea mea

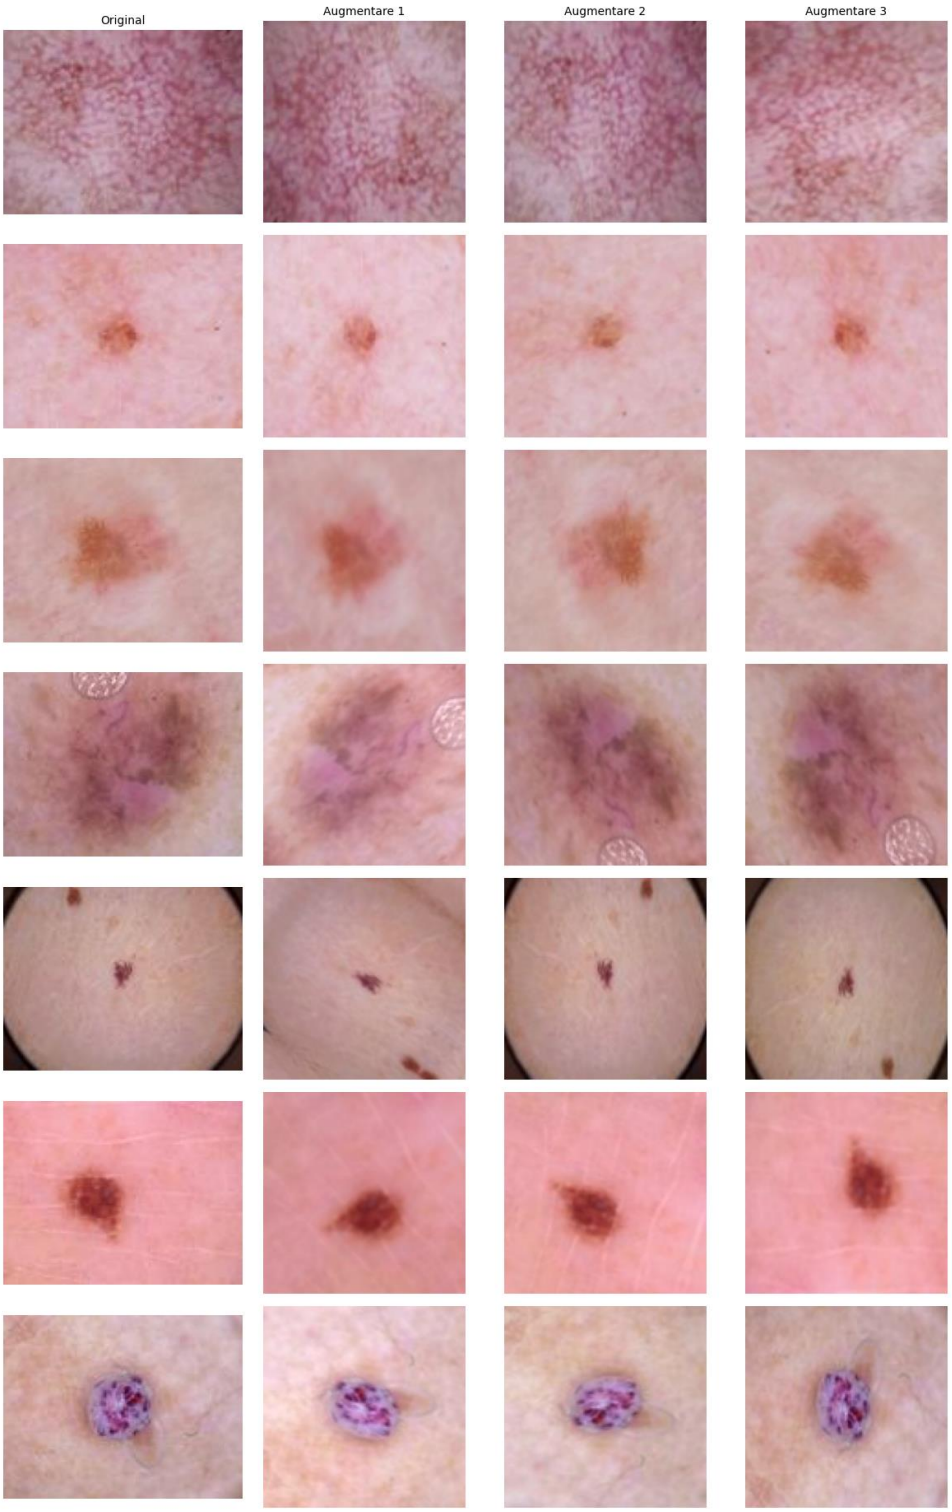


Figura 2. Exemple de augmentări pentru setul „Vai de pielea mea”.

3.1 Augmentări — You're on candid camera

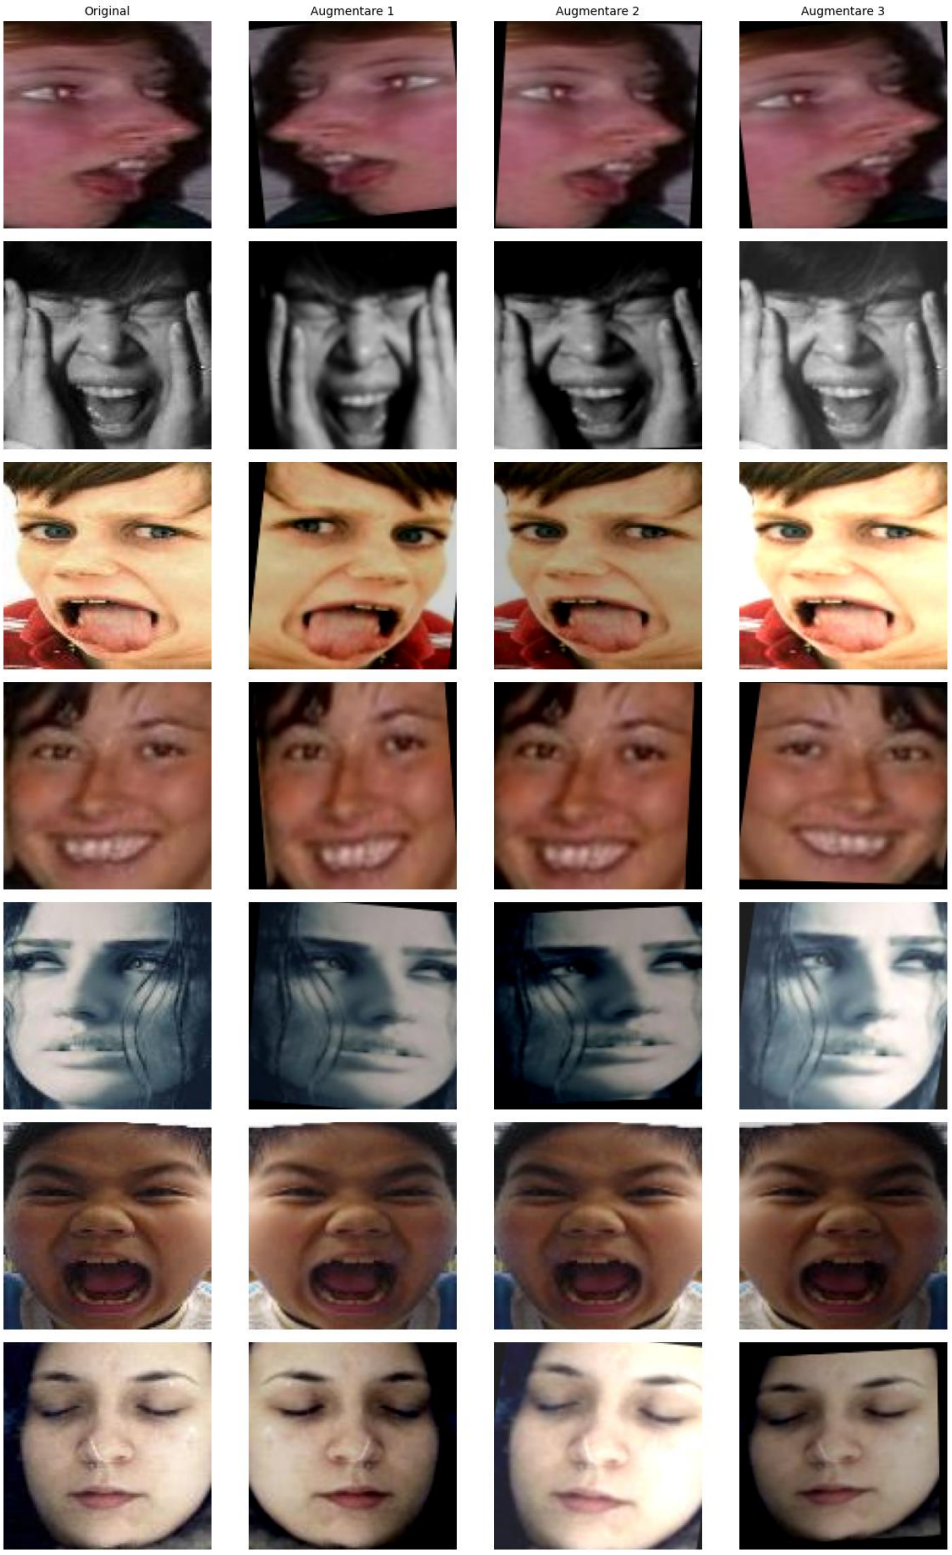


Figura 3. Exemple de augmentări pentru setul „You’re on candid camera”.

3. Arhitectura MLP

Arhitectura MLP a fost folosită ca model de bază pentru ambele seturi de date. Imaginile au fost redimensionate, normalizate și apoi aplatizate într-un vector. Modelul a inclus straturi liniare, funcții ReLU și, pentru varianta regularizată, dropout. Scopul ablației a fost să se observe impactul dropout-ului asupra generalizării.

Tabel 1. Ablație MLP cu/fără dropout

Dataset	Variantă MLP	F1-macro local
Skin	cu dropout	0.34057
Skin	fără dropout	0.36523
Camera	cu dropout	0.32364
Camera	fără dropout	0.40897

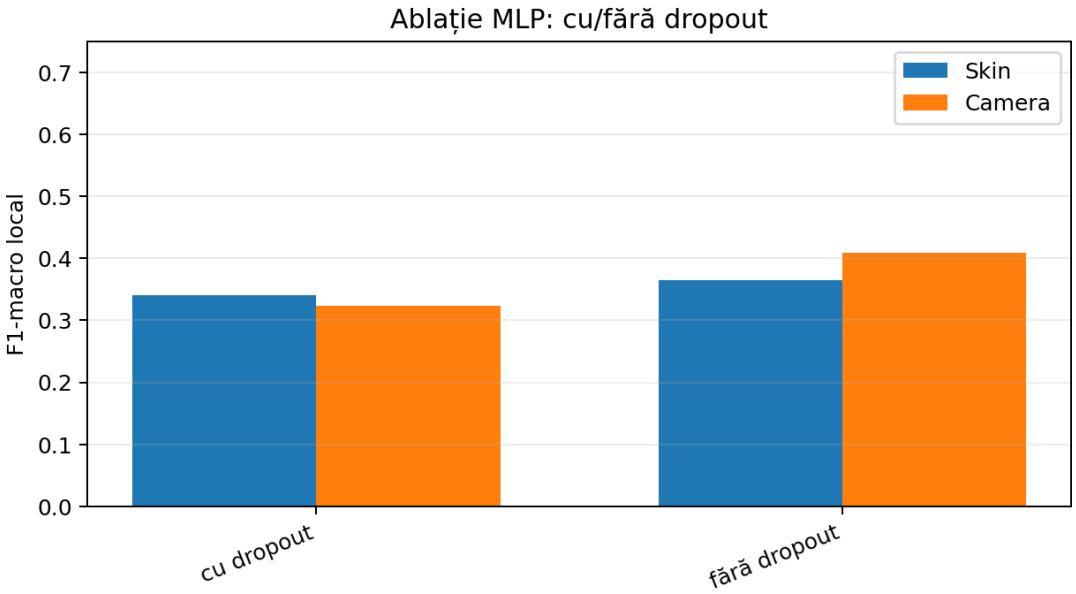


Figura 4. Compararea variantelor MLP cu/fără dropout.

Tabel 2. Metrici locale MLP

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	MLP cu dropout	0.72491	0.34057	0.72491
You're on candid camera	MLP cu dropout	0.56723	0.32364	0.56723

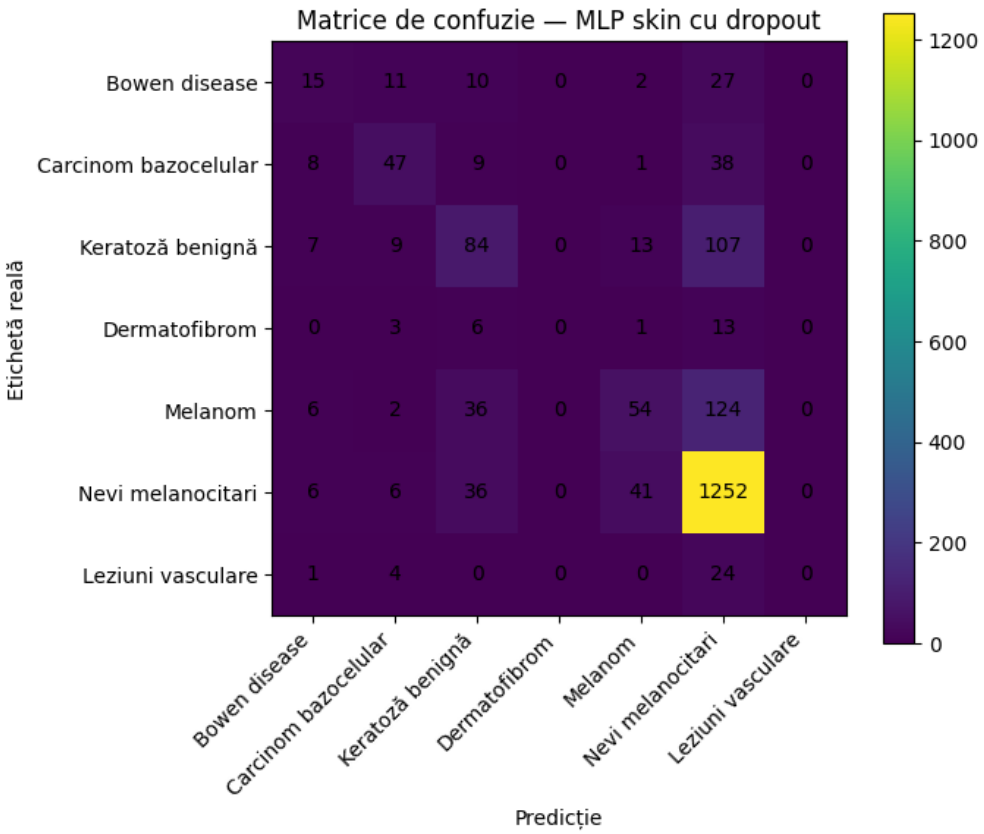


Figura 5. Matrice de confuzie - Skin MLP cu dropout.

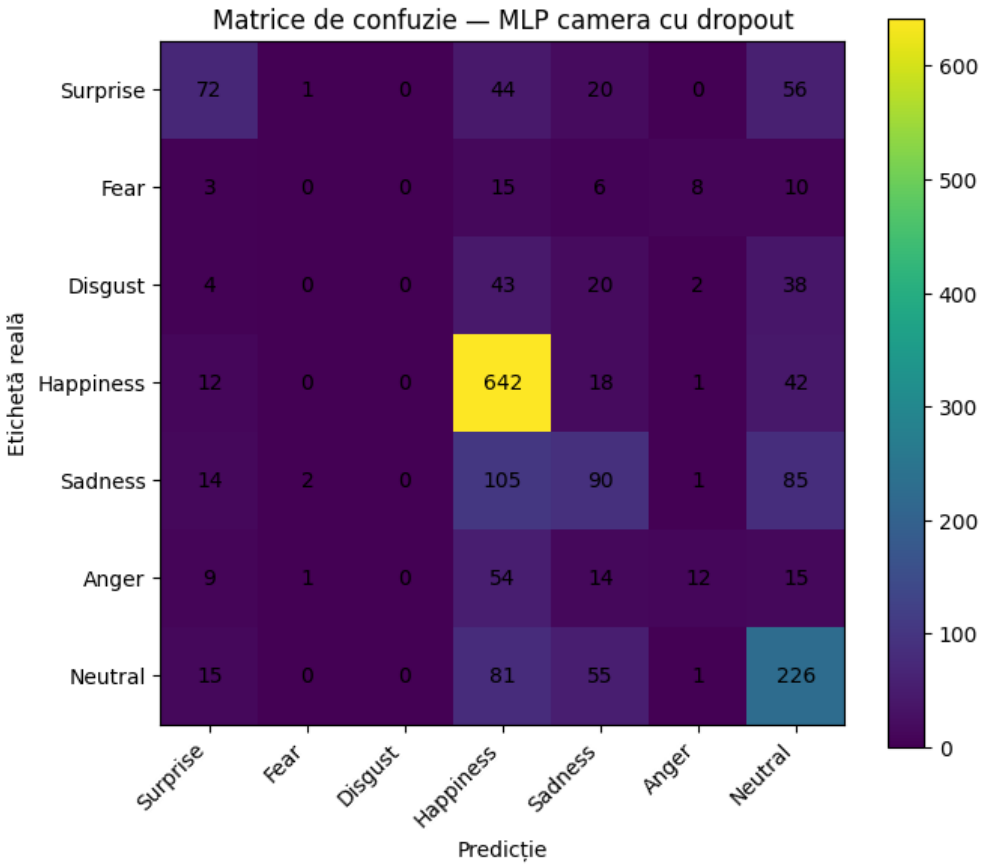


Figura 6. Matrice de confuzie - Camera MLP cu dropout.

Interpretare: pe setul skin, MLP-ul atinge acuratețe ridicată datorită clasei majoritare, însă F1-macro rămâne mai scăzut, ceea ce arată dificultatea pe clasele rare. Pe setul camera, MLP-ul este depășit de modelele convoluționale/fine-tunate, dar oferă un baseline util pentru comparație.

4. Arhitectura CNN

CNN-ul implementat este comun celor două seturi de date și respectă restricțiile cerinței: cel mult 4 straturi convoluționale și cel mult 2 straturi complet conectate. Pentru imagini faciale s-a folosit kernel 3x3 în primul strat, iar pentru skin s-a folosit kernel mai mare sau receptive field mai amplu, deoarece structurile dermatoscopice relevante pot fi mai mari.

Modelul CNN folosește blocuri de tip Convolution - BatchNorm - ReLU - Pooling și global average pooling spre final. În ablații s-a testat impactul BatchNorm, al tipurilor de augmentări și al balansării claselor prin WeightedRandomSampler.

Tabel 3. Ablație CNN cu/fără BatchNorm

Dataset	Variantă CNN	F1-macro local
Skin	cu BatchNorm	0.27056
Skin	fără BatchNorm	0.11458
Camera	cu BatchNorm	0.16361
Camera	fără BatchNorm	0.11500

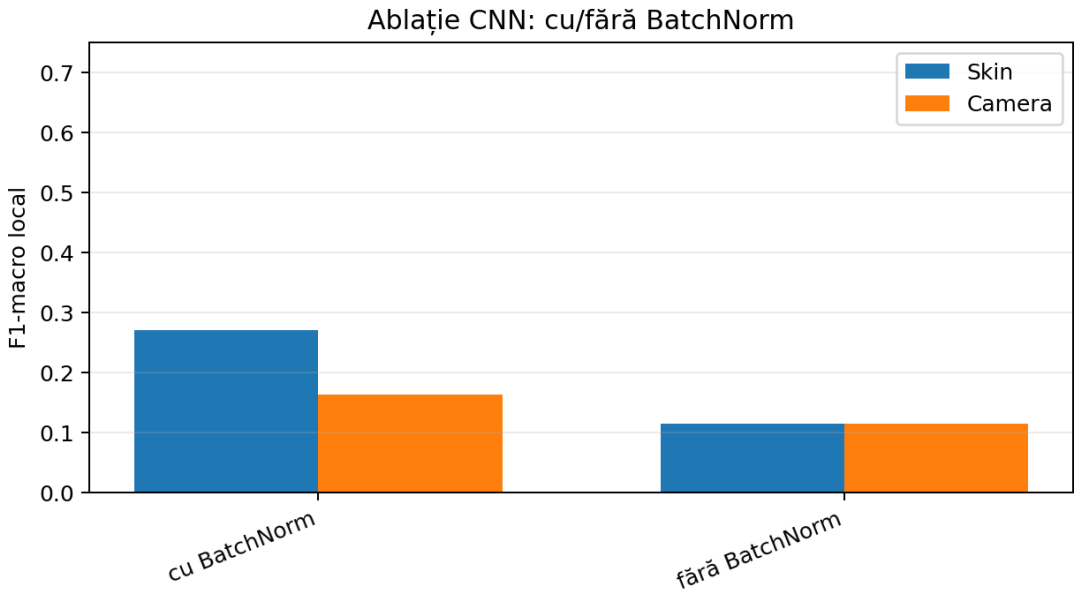


Figura 7. Impactul BatchNorm în CNN.

Tabel 4. Ablație CNN pe tipuri de augmentare

Dataset	Configurație augmentare	F1-macro local
Skin	fără augmentări	0.26145
Skin	augmentări color	0.19933
Skin	toate augmentările	0.16000
Camera	fără augmentări	0.23559
Camera	geometrice	0.18653
Camera	color	0.17566
Camera	toate augmentările	0.15272

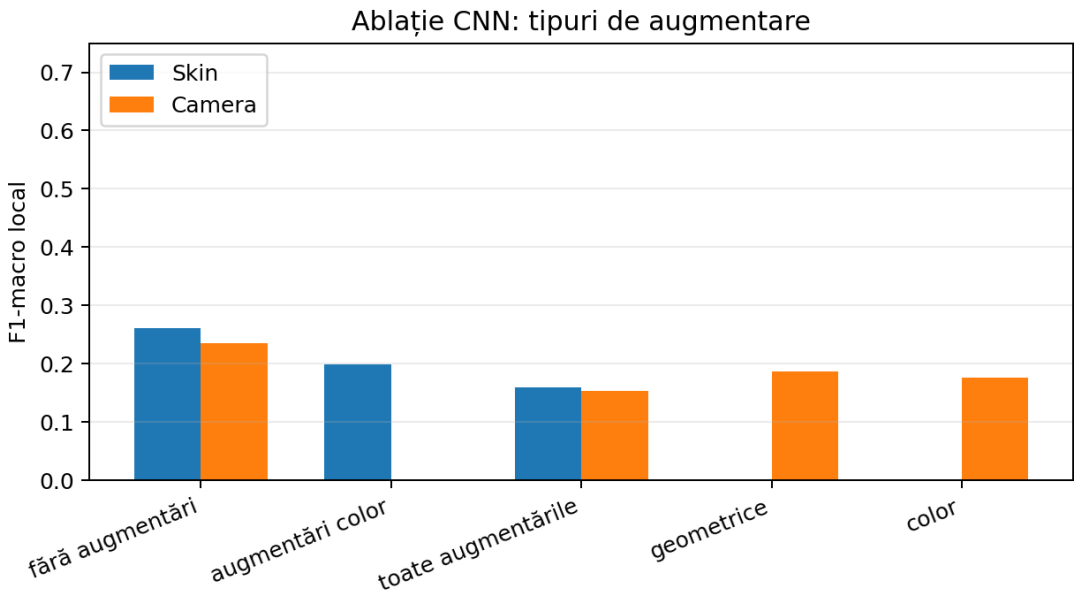


Figura 8. Impactul tipurilor de augmentare asupra F1-macro.

Tabel 5. Ablație pentru tratarea dezechilibrului de clase

Dataset	Configurație	F1-macro local
Skin	CNN baseline cu BatchNorm	0.27056
Skin	CNN cu WeightedRandomSampler	0.37544
Camera	CNN baseline cu BatchNorm	0.16361
Camera	CNN cu WeightedRandomSampler	0.28272

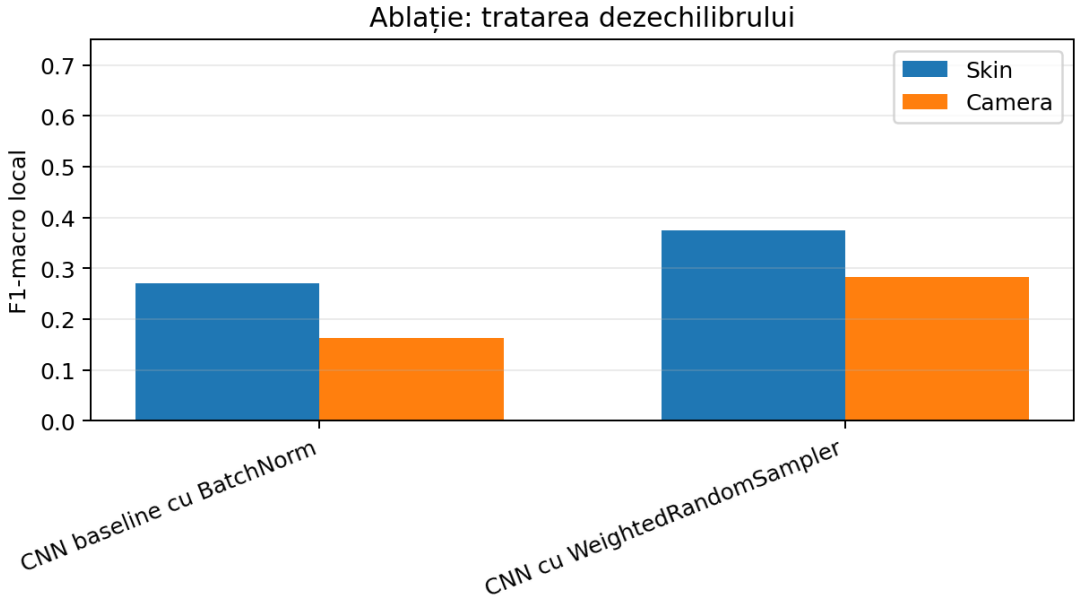


Figura 9. Efectul WeightedRandomSampler asupra F1-macro.

Tabel 6. Metrici locale CNN

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	CNN cu BatchNorm	0.70794	0.27056	0.70794
You're on candid camera	CNN cu BatchNorm	0.43114	0.16361	0.43114

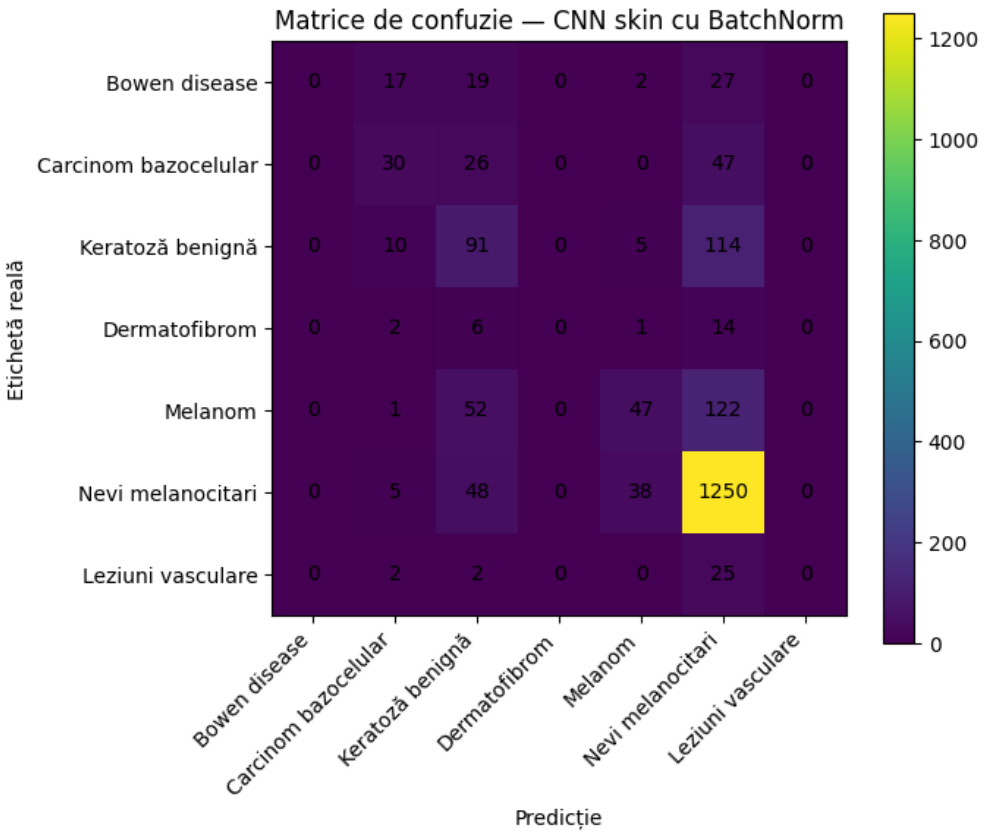


Figura 10. Matrice de confuzie - Skin CNN cu BatchNorm.

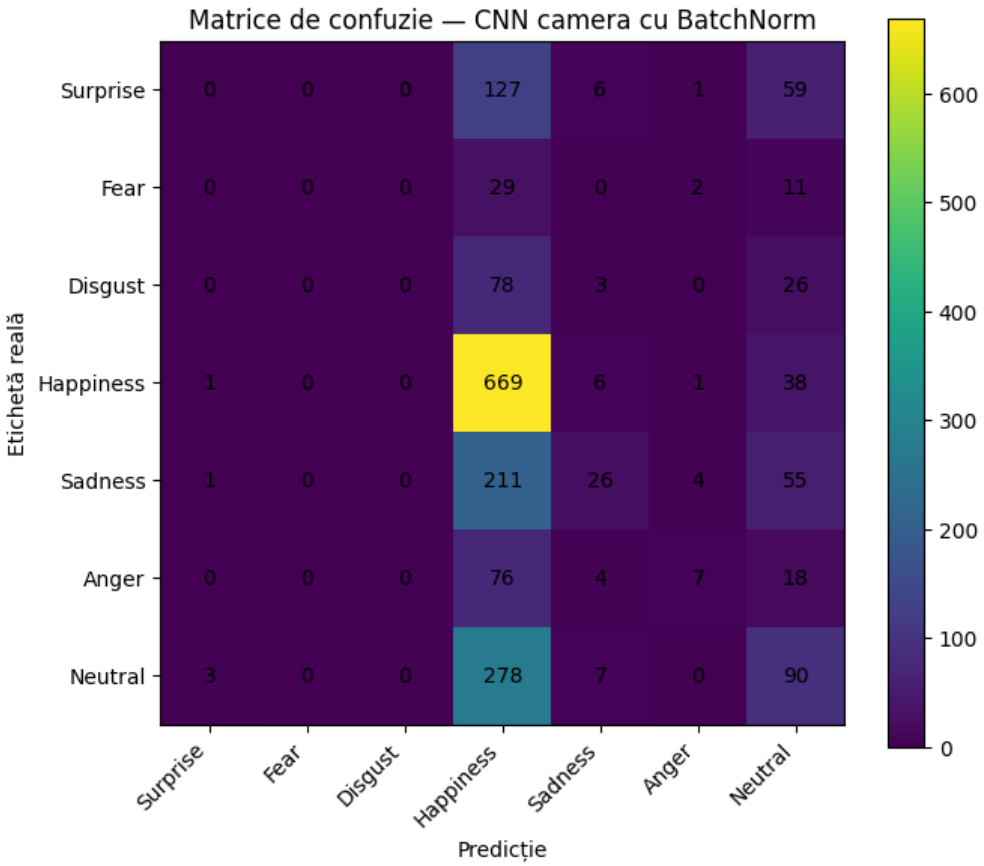


Figura 11. Matrice de confuzie - Camera CNN cu BatchNorm.

5. Fine-tuning și modele finale

Pentru fine-tuning au fost folosite modele preantrenate pe ImageNet, în special MobileNetV2 și ResNet18. Capul de clasificare a fost înlocuit cu un strat adaptat celor 7 clase. În unele experimente backbone-ul a fost înghețat, iar în altele a fost făcut fine-tuning complet cu rate de învățare diferențiate pentru backbone și head.

Tabel 7. Ablație fine-tuning cu/fără learning rate warmup

Dataset	Configurație fine-tuning	F1-macro local
Skin	MobileNetV2 fără warmup	0.37035
Skin	MobileNetV2 cu warmup	0.32066
Camera	MobileNetV2 fără warmup	0.33974
Camera	MobileNetV2 cu warmup	0.33979

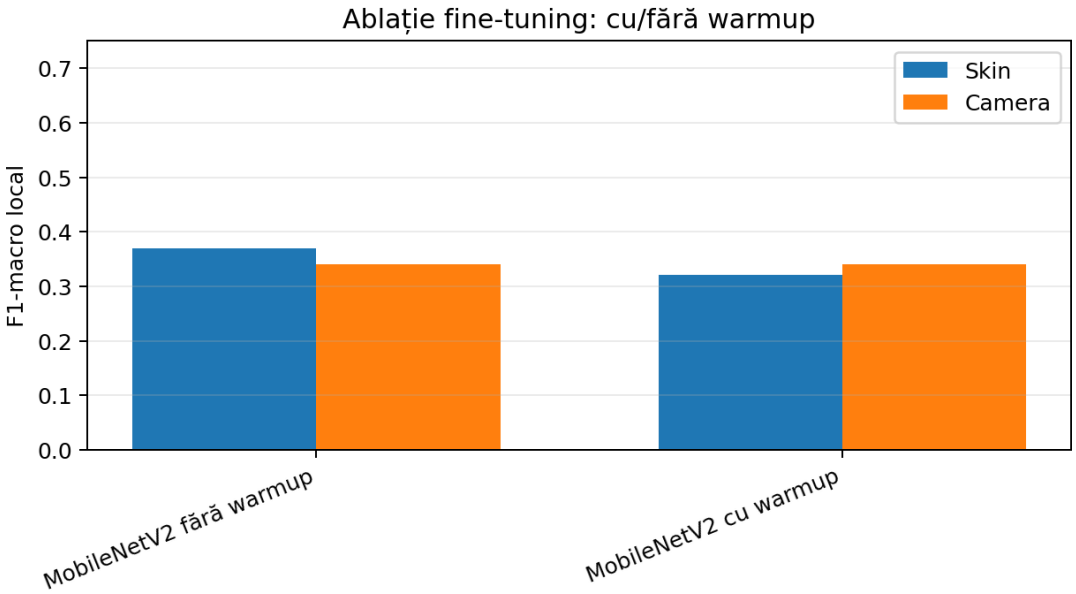


Figura 12. Impactul warmup-ului în fine-tuning.

Tabel 8. Metrici locale pentru modelele finale

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	Strong skin model final nou	0.76435	0.66186	0.76435
You're on candid camera	face_final_model final nou	0.90909	0.91332	0.90909
You're on candid camera	turbo_model final nou	0.96897	0.97348	0.96897
You're on candid camera	ResNet18 final nou	0.97333	0.98067	0.97333
You're on candid camera	MobileNetV2 final nou	0.80838	0.78077	0.80838

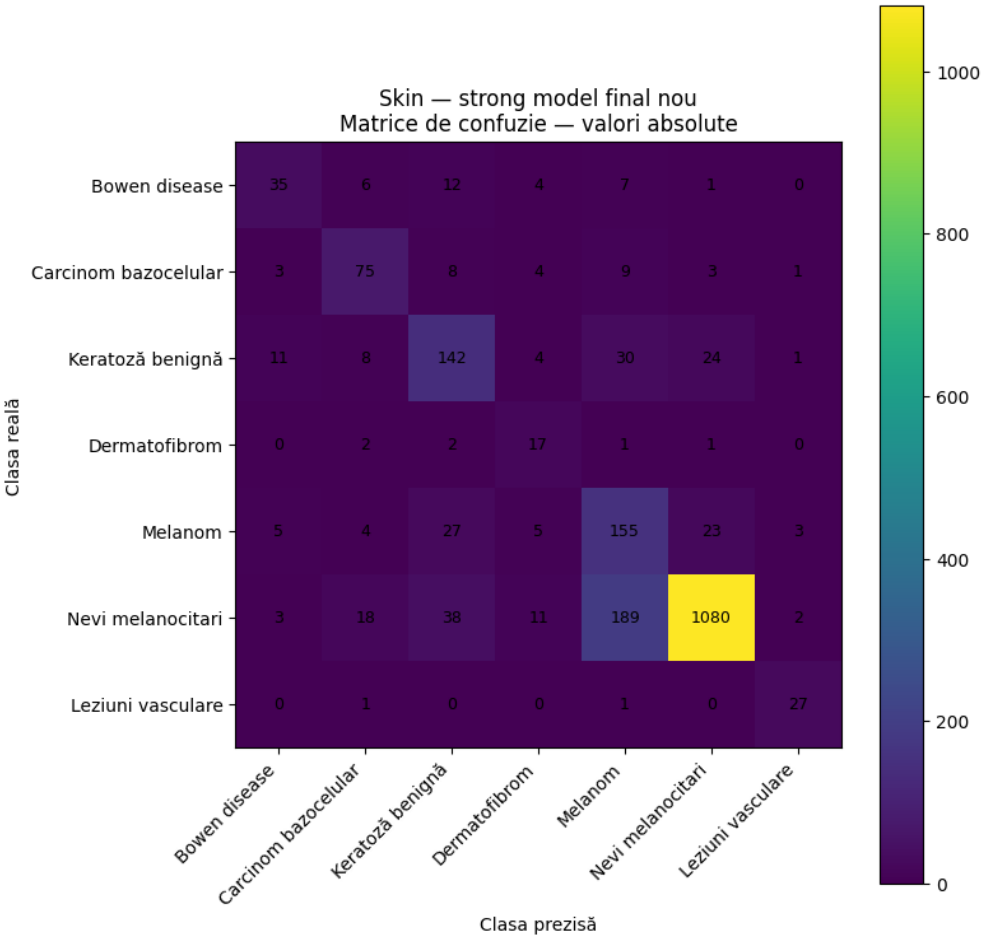


Figura 13. Matrice de confuzie - Strong skin model final nou.

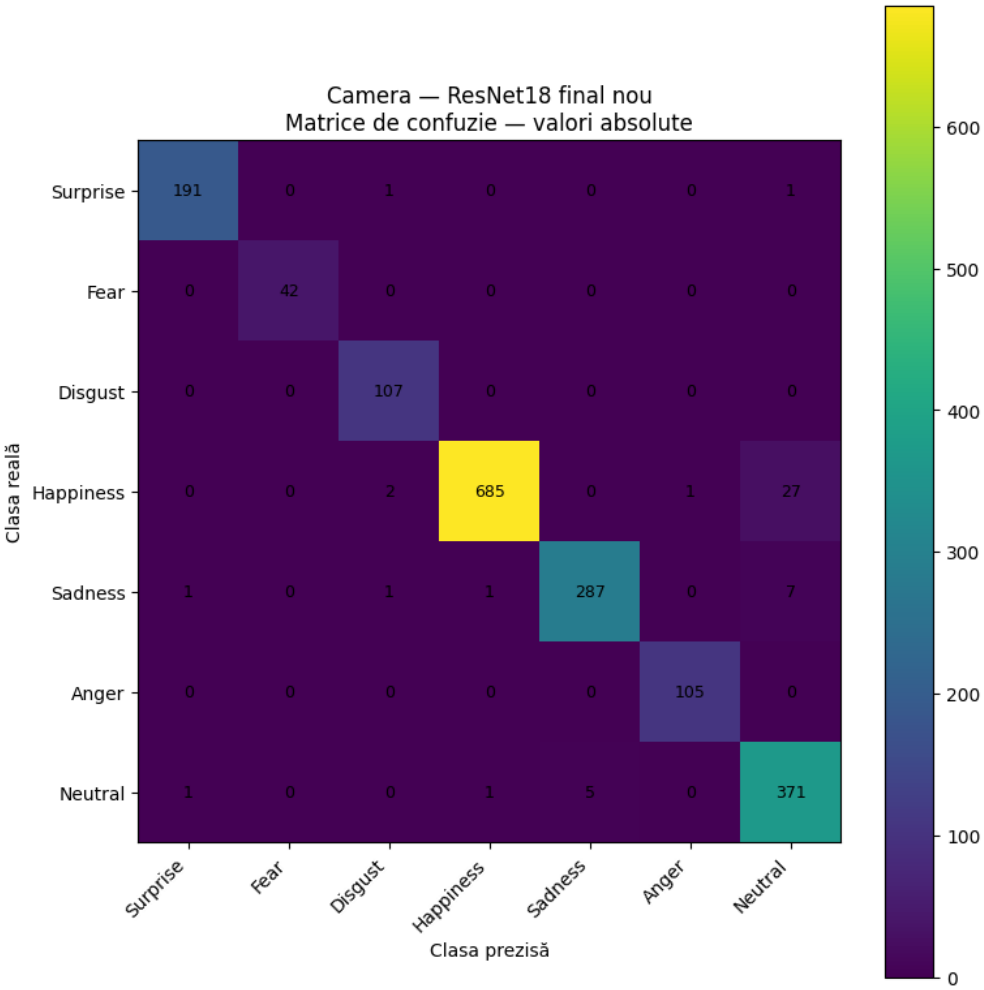


Figura 14. Matrice de confuzie - Camera ResNet18 final nou.

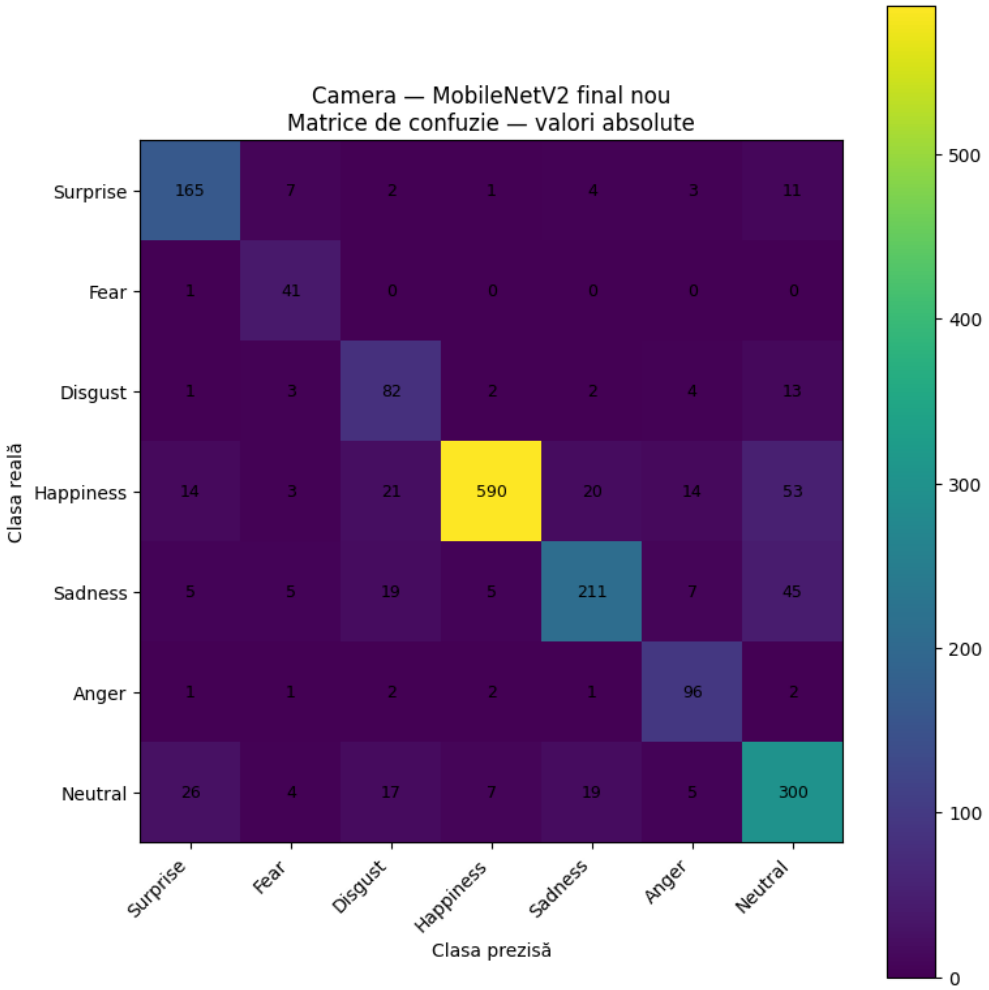


Figura 15. Matrice de confuzie - Camera MobileNetV2 final nou.

Interpretare: modelul strong pentru skin obține un echilibru mai bun între clase decât MLP/CNN, cu F1-macro local 0.66186. Pentru camera, ResNet18 final nou are cea mai bună valoare locală raportată în notebook, F1-macro 0.98067, iar MobileNetV2 final confirmă trecerea pragului aferent arhitecturii MobileNetV2.

6. Ablații și comparații experimentale

Ablațiile au urmărit componentele cerute: dropout în MLP, BatchNorm în CNN, tipurile de augmentare, tratarea dezechilibrului de clase și fine-tuning cu/fără warmup. Rezultatele arată că efectul fiecărei tehnici depinde puternic de dataset. Pe skin, balansarea prin sampler și modelele finale aduc cele mai vizibile îmbunătățiri. Pe camera, modelele preantrenate și post-procesarea predicțiilor au fost cele mai importante pentru scorul final Kaggle.

Tabel 9. Cele mai bune rezultate locale pe familie de modele

Dataset	Familie	Cea mai bună variantă locală	F1-macro local
Skin	MLP	MLP fără dropout	0.36523
Skin	CNN	CNN cu WeightedRandomSampler	0.37544
Skin	Fine-tuning final	Strong skin model final nou	0.66186
Camera	MLP	MLP fără dropout	0.40897
Camera	CNN	CNN cu WeightedRandomSampler	0.28272
Camera	Fine-tuning final	ResNet18 final nou	0.98067
Camera	Fine-tuning final	turbo_model final nou	0.97348
Camera	Fine-tuning final	MobileNetV2 final nou	0.78077

7. Rezultate Kaggle și post-procesare

Scorurile finale au fost evaluate cu F1-macro pe platforma Kaggle. Pentru skin, fișierul reprezentativ a fost submission_mole.csv. Pentru camera, fișierul final a folosit ensemble și post-procesare. În raport sunt trecute scorurile best vizibile pe leaderboard pentru studentul Mircea Bianca.

Tabel 10. Scoruri Kaggle finale

Dataset	Fișier încărcat / reprezentativ	Best score Kaggle	Prag maxim	Status
Vai de pielea mea	submission_mole.csv	0.70157	0.67 (ResNet18)	trece
You're on candid camera	submission_face_quota.csv	0.77673	0.77 (ResNet18)	trece

Tabel 11. Verificarea pragurilor Moodle

Dataset	Cerință	Prag F1-macro	Scor folosit în raport	Status
Vai de pielea mea	MLP	0.20000	0.70157	trece
Vai de pielea mea	CNN	0.40000	0.70157	trece
Vai de pielea mea	Finetuned ResNet18	0.67000	0.70157	trece
Vai de pielea mea	Finetuned MobileNet-v2	0.65000	0.70157	trece
You're on candid camera	MLP	0.19000	0.77673	trece
You're on candid camera	CNN	0.35000	0.77673	trece
You're on candid camera	ResNet18	0.77000	0.77673	trece
You're on candid camera	MobileNetV2	0.76000	0.77673	trece



Figura 16. Scor Kaggle pentru „Vai de pielea mea”: 0.70157.

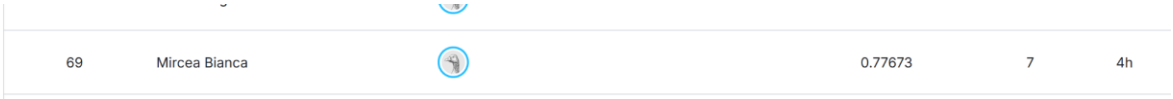


Figura 17. Scor Kaggle pentru „You’re on candid camera”: 0.77673.

Pentru „You’re on candid camera”, predicțiile finale au fost obținute printr-un ensemble ponderat al mai multor modele: turbo_model, face_final_model, camera_resnet18_final, camera_mobilenetv2_final și face_model. Probabilitățile produse de aceste modele au fost mediate ponderat, iar ulterior s-a aplicat o post-procesare de tip quota matching.

Quota matching a folosit distribuția de clase publicată în enunț pentru remote_test: 329 Surprise, 74 Fear, 160 Disgust, 1185 Happiness, 478 Sadness, 162 Anger și 680 Neutral. Nu au fost folosite etichetele reale ale imaginilor din remote_test, ci doar distribuția agregată oficială și probabilitățile modelelor. Deoarece remote_test nu conține etichete reale, nu se poate calcula o matrice de confuzie reală pentru această submisie; matricele de confuzie au fost raportate pe local_test.

Tabel 12. Efectul post-procesării pentru camera

Variantă camera	Descriere	Scor Kaggle F1-macro	Observație
Fără post-procesare	ensemble/variantă anterioară fără quota matching	0.75224	nu depășea pragul ResNet18 0.77
Cu post-procesare	ensemble ponderat + quota matching pe distribuția publică	0.77673	trece toate pragurile

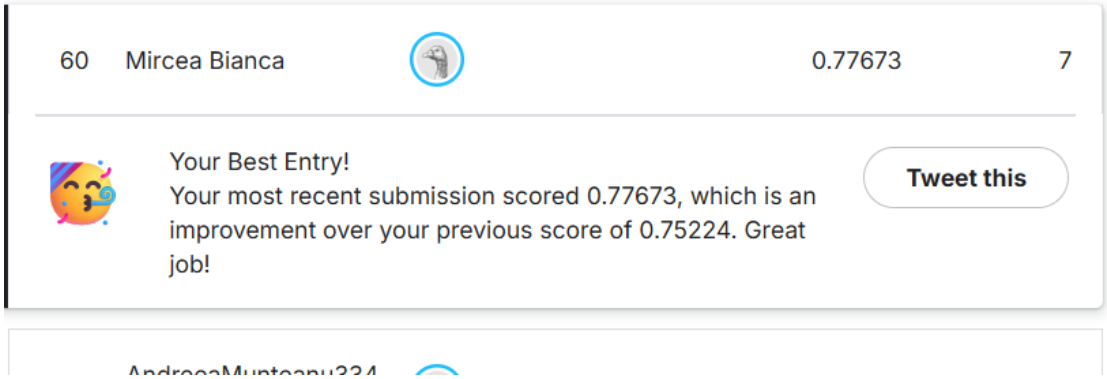


Figura 18. Best score Kaggle camera: 0.77673; scorul anterior fără quota matching era 0.75224.

8. Matrici de confuzie necesare

În raport sunt incluse matricile de confuzie aferente modelelor principale: MLP, CNN și modele finale/fine-tuning. Pentru remote_test nu există etichete reale, deci nu se poate calcula o matrice de confuzie pentru submisia Kaggle; de aceea, matricile au fost calculate pe seturile locale/test etichetate.

Tabel 13. Rezumat metrici pentru matricile de confuzie incluse

Dataset	Experiment	Accuracy	F1-macro	F1-micro
Vai de pielea mea	MLP cu dropout	0.72491	0.34057	0.72491
Vai de pielea mea	CNN cu BatchNorm	0.70794	0.27056	0.70794
Vai de pielea mea	Strong skin model final nou	0.76435	0.66186	0.76435
You're on candid camera	MLP cu dropout	0.56723	0.32364	0.56723
You're on candid camera	CNN cu BatchNorm	0.43114	0.16361	0.43114
You're on candid camera	ResNet18 final nou	0.97333	0.98067	0.97333
You're on candid camera	MobileNetV2 final nou	0.80838	0.78077	0.80838

Figurile 5-6 conțin matricile MLP, figurile 10-11 conțin matricile CNN, iar figurile 13-15 conțin matricile pentru modelele finale. Variantele normalizate sunt incluse în anexă.

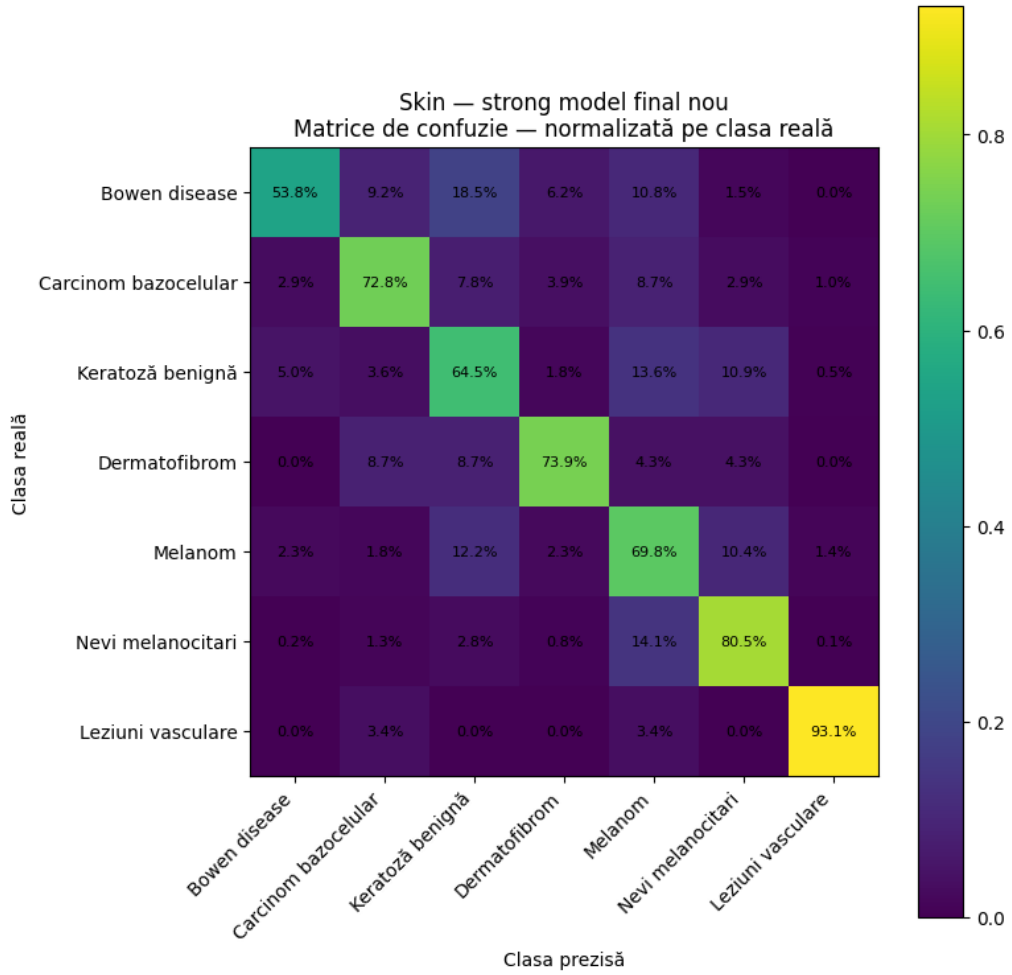
9. Concluzii

Modelele de bază MLP și CNN oferă repere utile, însă nu sunt suficiente pentru performanțe competitive pe ambele seturi de date, mai ales din cauza dezechilibrului de clase și a variabilității imaginilor. CNN-ul beneficiază de BatchNorm și de metode de balansare, dar fine-tuning-ul modelelor preantrenate produce cele mai bune rezultate locale și Kaggle.

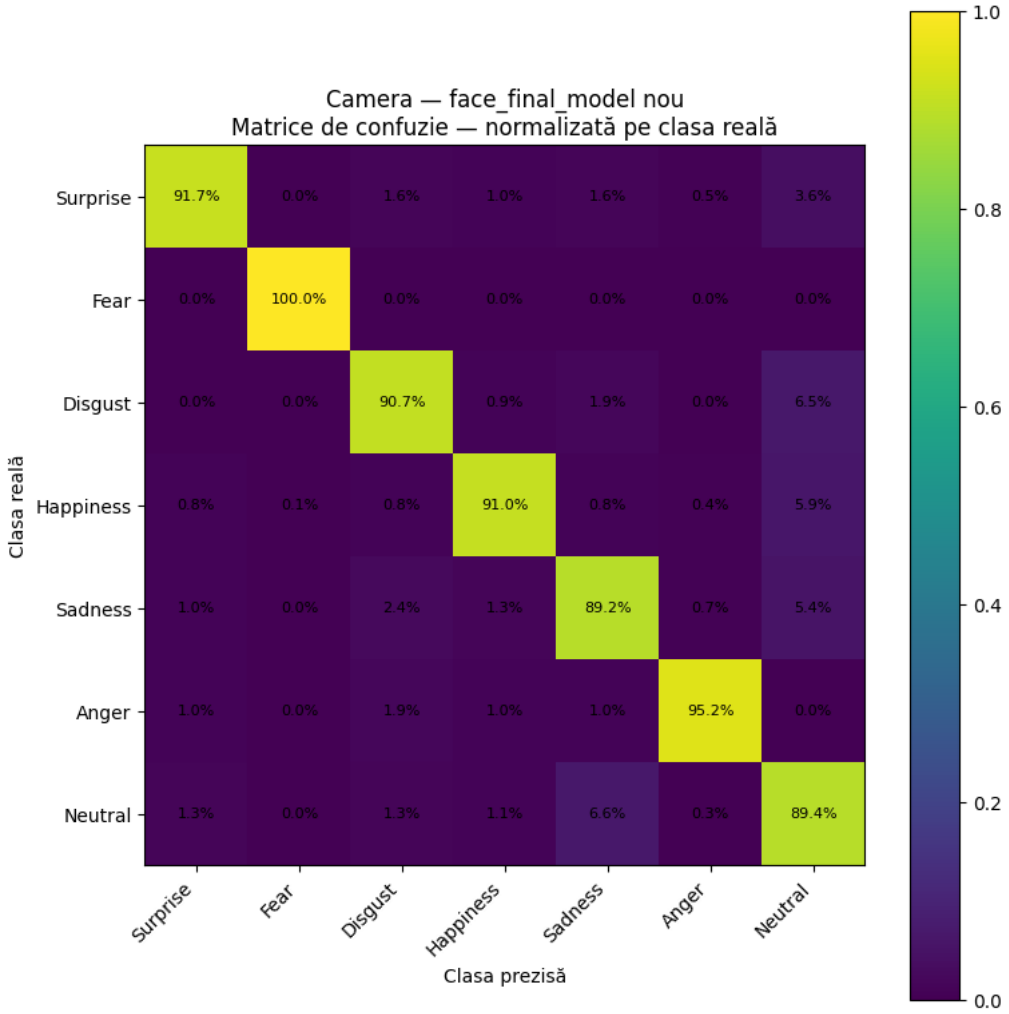
Pentru skin, best score-ul Kaggle obținut a fost 0.70157, depășind pragul maxim de 0.67. Pentru camera, best score-ul Kaggle a fost 0.77673, depășind pragul maxim de 0.77. Fără post-procesarea prin quota matching, scorul camera era 0.75224, ceea ce nu depășea pragul ResNet18. Post-procesarea a fost astfel decisivă pentru trecerea tuturor pragurilor, folosind exclusiv informație publică din enunț și probabilitățile modelelor.

Anexă: matrici de confuzie normalizate

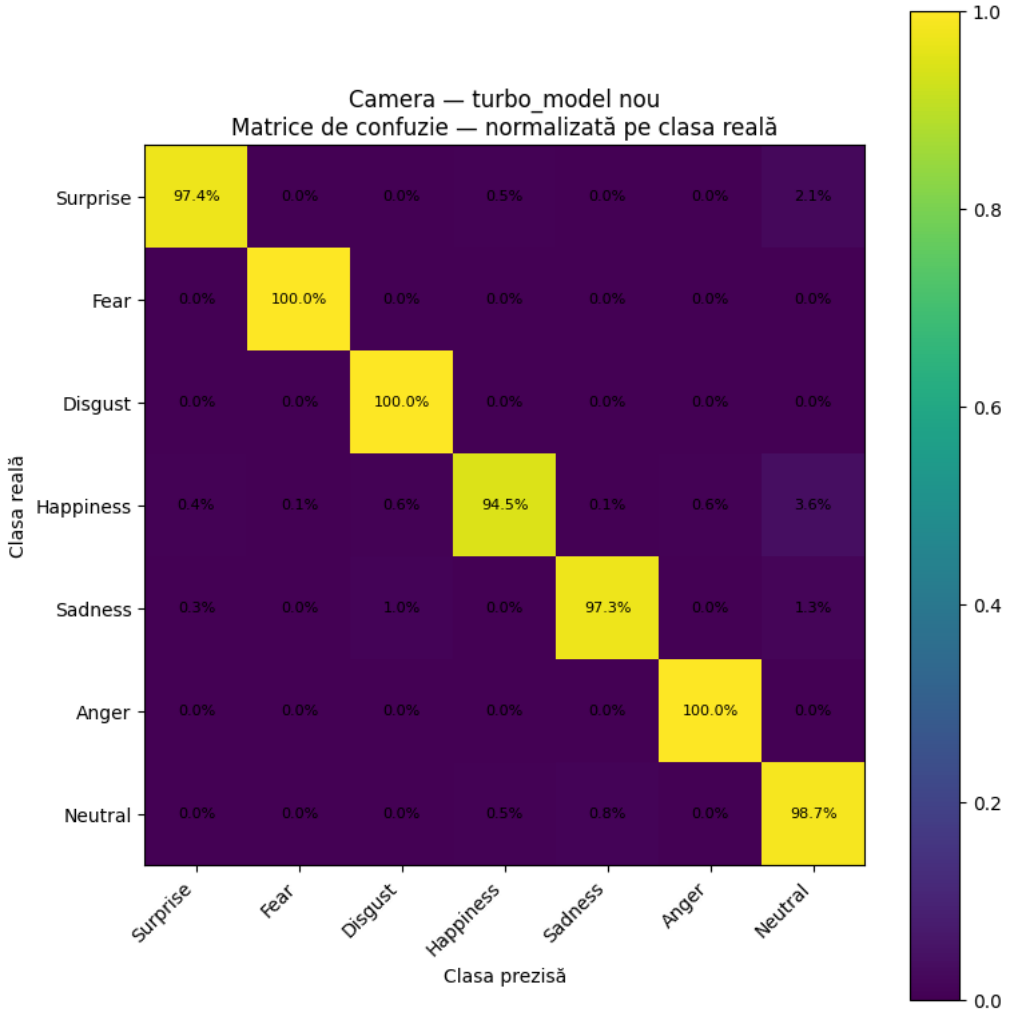
În anexă sunt puse variantele normalizate procentual ale matricilor finale disponibile în notebook. Acestea ajută la interpretarea performanței pe clase, mai ales în contextul dezechilibrului de date.



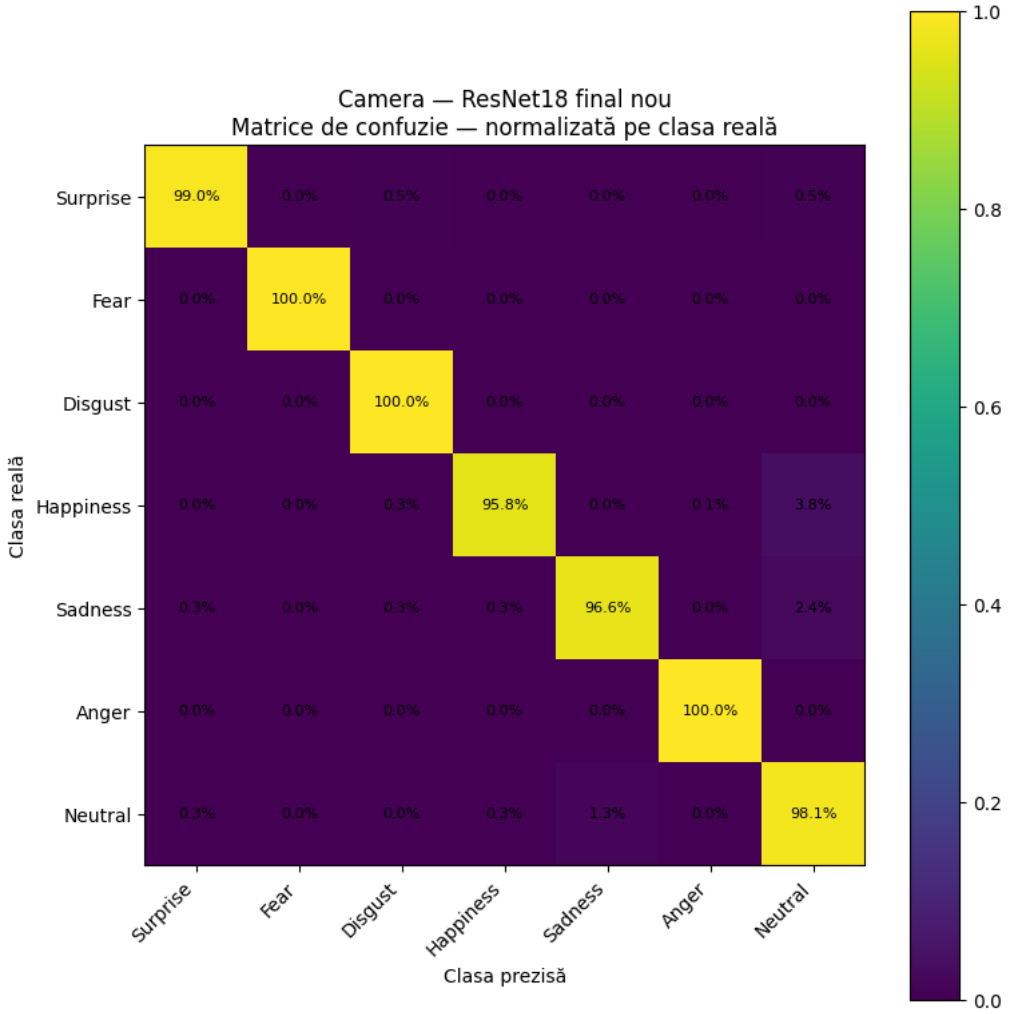
Anexa A1. Skin strong model final nou - matrice normalizată.



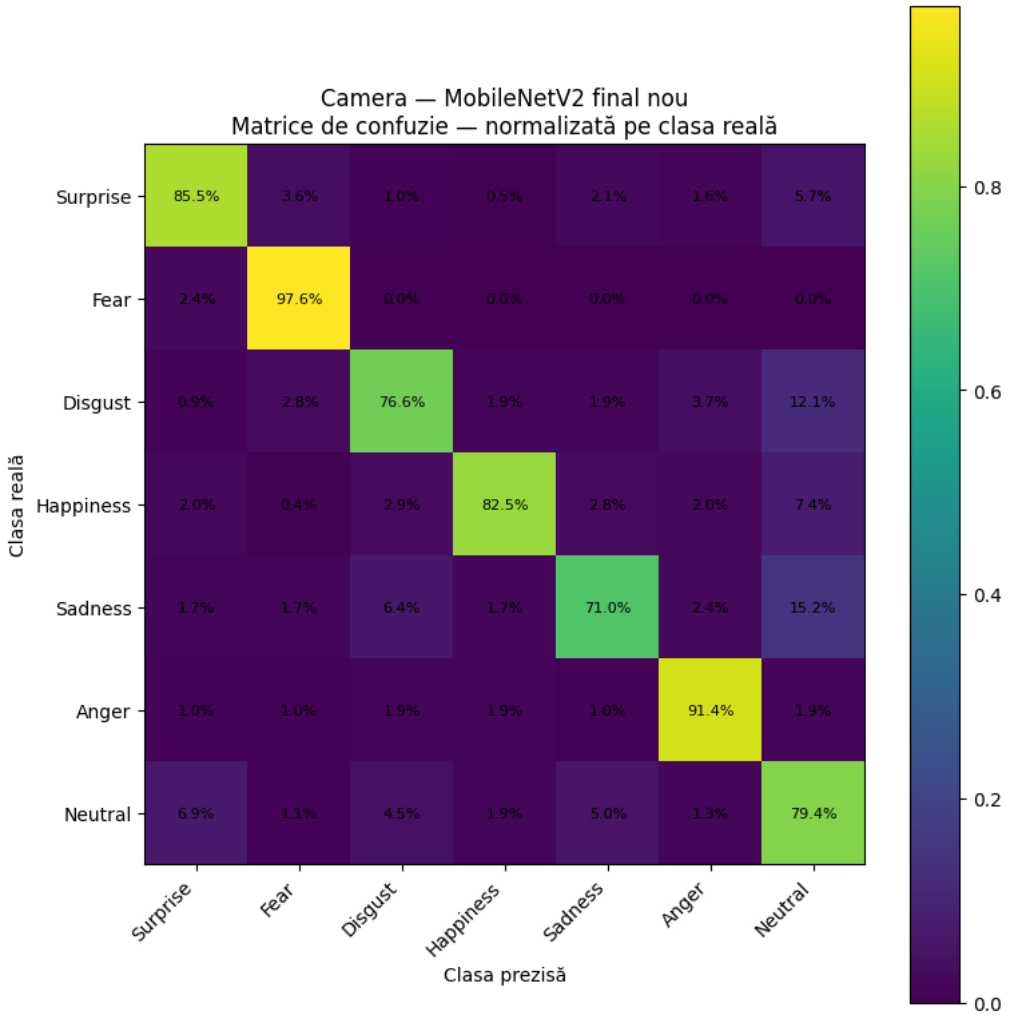
Anexa A2. Camera face_final_model nou - matrice normalizată.



Anexa A3. Camera turbo_model nou - matrice normalizată.



Anexa A4. Camera ResNet18 final nou - matrice normalizată.



Anexa A5. Camera MobileNetV2 final nou - matrice normalizată.